Informe de investigación técnica: Desaparición de OpenCode Free en OmniRoute, análisis del error HTTP 499 y resolución del conflicto cronológico

1. Contexto operativo y resolución de la disonancia cronológica 2
2. Causa raíz del bloqueo upstream y la crisis de estabilidad (Issue #3061) 3
3. Retiro formal del proveedor y cambio de modelo hacia OpenCode Zen y Go 4
4. Análisis del comportamiento de timeout y desconexión (HTTP 499) 5
5. Matriz comparativa de la integración de proveedores 6
6. Conclusiones y recomendaciones definitivas 7
Recomendaciones estratégicas para el flujo de trabajo 7
Obras citadas 8

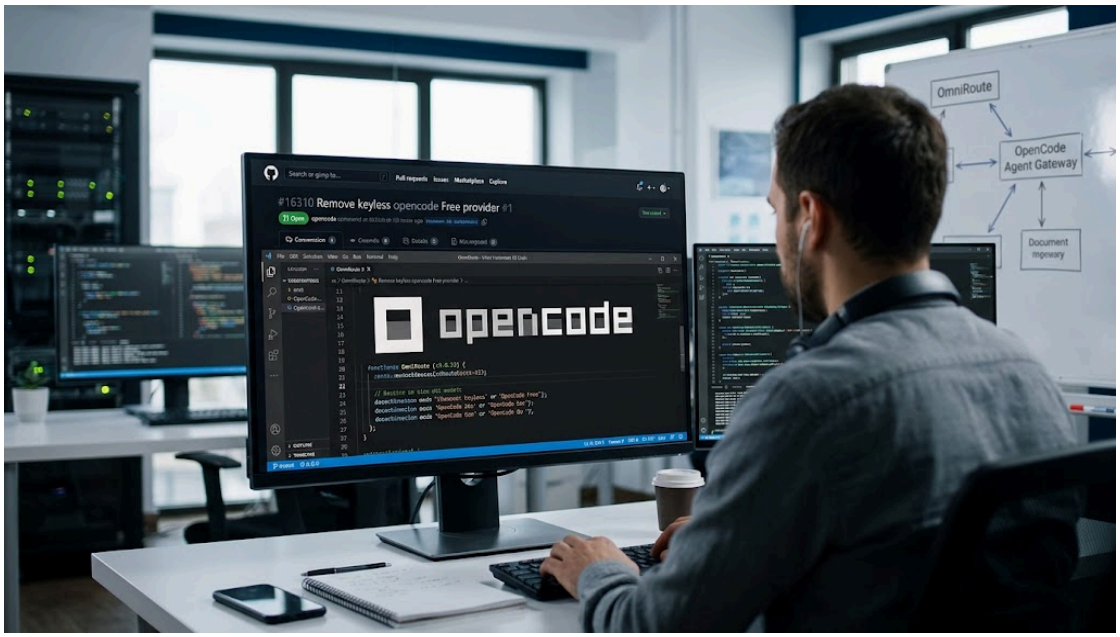


1. Contexto operativo y resolución de la disonancia cronológica

La integración entre la pasarela local de inteligencia artificial OmniRoute y el agente de programación OpenCode ha experimentado cambios arquitectónicos significativos a lo largo del año 2026[1]. La duda planteada por la presencia de tutoriales y vídeos en plataformas como YouTube durante septiembre de 2026 que aún mostraban la opción de proveedor gratuito "OpenCode Free" —frente a la situación actual donde únicamente figuran las modalidades OpenCode Zen y OpenCode Go— no responde a un error individual o de configuración en el equipo del usuario[2]. Por el contrario, obedece a un cambio sistemático en el código fuente de OmniRoute efectuado en la segunda mitad de octubre de 2026[3].

Históricamente, OmniRoute incorporaba un proveedor preconfigurado sin autenticación (*keyless*) denominado opencode u "OpenCode Free", diseñado para realizar peticiones directas a la infraestructura pública de OpenCode sin exigir la introducción de claves de API (sk-...)[5]. Esta funcionalidad se mantuvo activa durante la primavera y el verano de 2026, lo que propició la creación de abundante contenido divulgativo durante el mes de septiembre en el que se promocionaba esta configuración de coste cero[2].

Sin embargo, el hito determinante en el ciclo de vida de este proveedor ocurrió el 19 de octubre de 2026 con la publicación de la versión v3.8.52 de OmniRoute[3]. A través de la solicitud de cambio (*Pull Request*) #16310, el equipo de desarrollo de OmniRoute eliminó definitivamente la opción keyless "OpenCode Free" de su registro central de proveedores[3]. En consecuencia, los vídeos grabados en septiembre reflejaban con precisión el estado del software en la fecha de su producción, mientras que las instalaciones actuales a partir de la versión v3.8.52 ya no incluyen dicho proveedor en la interfaz[2].



2. Causa raíz del bloqueo upstream y la crisis de estabilidad (Issue #3061)

La eliminación del proveedor gratuito no se produjo de manera arbitraria, sino como respuesta a una incompatibilidad técnica insalvable surgida por el endurecimiento de las políticas de seguridad de OpenCode y a un fallo de infraestructura en las instancias locales de OmniRoute[3].

A medida que OpenCode consolidó su modelo de negocio mediante los servicios OpenCode Zen (pasarela de modelos verificados bajo demanda) y OpenCode Go (suscripción empaquetada de $10 mensuales), su equipo de infraestructura implementó validaciones estrictas del origen de las peticiones en sus endpoints públicos (https://opencode.ai/zen/v1)[6].

La infraestructura de OpenCode comenzó a rechazar de forma sistemática cualquier solicitud entrante que no procediera de la aplicación oficial nativa de OpenCode, devolviendo el mensaje de error explícito: *OpenCode's free tier can only be used from within OpenCode[3].

Al no enviar una cabecera Authorization válida debido a su diseño noAuth: true, la pasarela OmniRoute empezó a recibir respuestas consecutivas con código de estado HTTP 401 Unauthorized o 403 Forbidden desde los servidores de OpenCode3. Esta situación desencadenó una falla crítica documentada en la incidencia #3061 de OmniRoute6.

Cuando un proveedor keyless recibía un error 401 persistente, la lógica de recuperación de OmniRoute en src/sse/handlers/chat.ts intentaba excluir la conexión añadiendo el identificador dinámico "noauth" al conjunto de conexiones excluidas[6].

No obstante, el servicio de autenticación en src/sse/services/auth.ts evaluaba la condición de proveedor sin clave en las primeras líneas de ejecución y retornaba inmediatamente la credencial sintética "noauth", omitiendo la verificación del conjunto de exclusión[6].

Al mismo tiempo, la función encargada de aplicar tiempos de enfriamiento (cooldown), updateProviderConnection(), ejecutaba una sentencia SQL UPDATE dirigida al identificador "noauth"[6].

Al no existir un registro real en la base de datos para esa pseudoconexión, la actualización afectaba a cero filas y el tiempo de pausa no se guardaba[6].

Esto provocaba que OmniRoute entrara en un bucle infinito de reintentos en milisegundos[6]. En cada iteración, la pasarela escribía registros de fallos de salud y logs de eventos en el disco local, provocando la saturación completa del almacenamiento en las máquinas de los usuarios[6].



Ejemplo explicativo debido a la superación de los límites de tasa.

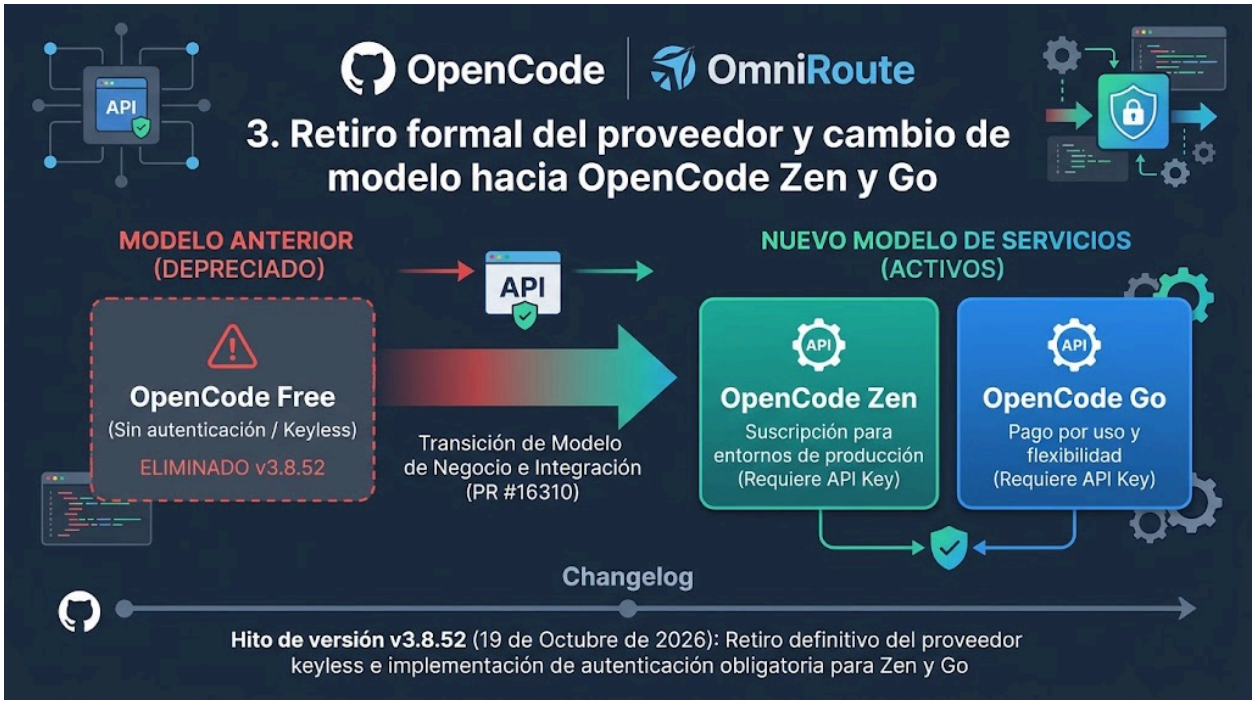
3. Retiro formal del proveedor y cambio de modelo hacia OpenCode Zen y Go

Frente al riesgo de denegación de servicio local en las instalaciones de los usuarios y tras recibir una solicitud formal por parte de los operadores de OpenCode, los mantenedores de OmniRoute oficializaron la retirada completa de la integración keyless[3]. La documentación de referencia del repositorio registró la desactivación permanente del nivel gratuito no autenticado, manteniendo únicamente el soporte para integraciones que utilicen claves de API legítimas de los planes pagados o en fase beta controlada[3].

El ecosistema actual de OpenCode se articula a través de dos modalidades autenticadas bien diferenciadas:

- **OpenCode Zen:** Funciona como un enrutador curado que da acceso a modelos probados específicamente para flujos de trabajo con agentes[8]. Aunque ofrece acceso a modelos promocionales de coste cero por tiempo limitado (como big-pickle o grok-code-fast-1), su infraestructura requiere que el usuario inicie sesión, registre un perfil y obtenga una clave de API autenticada[8].
- **OpenCode Go:** Constituye una suscripción mensual fija de $10 que asigna un presupuesto equivalente en dólares estructurado en ventanas rodantes de 5 horas, semanales y mensuales[9].Permite derivar el exceso de consumo hacia el saldo de una cuenta Zen[9].

Tanto OpenCode Zen como OpenCode Go requieren la emisión de una clave API en formato estándar[6]. Por esta razón, OmniRoute conserva únicamente los conectores específicos para opencode-zen y opencode-go, exigiendo al usuario la introducción de sus credenciales privadas para realizar cualquier petición HTTP saliente[3].



4. Análisis del comportamiento de timeout y desconexión (HTTP 499)

Cuando se intenta omitir la ausencia del proveedor nativo "OpenCode Free" creando manualmente un nodo personalizado de tipo OpenAI Compatible en OmniRoute con una API Key ficticia (como sk-dummy o free) dirigida a modelos como big-pickle, la petición falla inexorablemente en la capa de transmisión[13].

Los registros de diagnóstico de peticiones de OmniRoute evidencian con precisión el mecanismo de fallo subyacente[13]. Al recibir una solicitud desde el cliente, OmniRoute transforma la petición y emite una llamada HTTP de tipo POST hacia el endpoint de inferencia con las propiedades "stream": true y "stream_options": {"include_usage": true}[13]. La respuesta de la infraestructura de OpenCode exhibe la siguiente firma técnica en la telemetría del gateway[13]:

- **Apertura de socket sin transmisión de datos:** El servidor de OpenCode acepta la conexión TCP inicial pero, al no detectar los tokens de sesión de cliente ni la cabecera de autorización de Zen/Go, suspende el procesamiento de la inferencia[3].
- **Conteo de eventos nulo (_eventCount: 0):** La respuesta del proveedor no genera ningún evento de tipo *Server-Sent Events* (SSE)[13]. El flujo de datos no emite ningún bloque con la estructura data: {"choices": [...]}[13].
- **Métricas de consumo en cero:** El registro del pipeline confirma tokens: {in: 0, out: 0}, con un valor nulo en el tiempo de emisión del primer token (ttft: null)[13].
- **Cancelación por desconexión de cliente (status: 499):** Tras mantener la solicitud abierta durante un intervalo comprendido entre 11.800 y 18.500 milisegundos, el cliente o la

propia señal interna de tiempo límite de OmniRoute aborta la conexión, devolviendo el error Client disconnected: request_signal_aborted[13].

Este comportamiento confirma de forma categórica que los modelos internos y gratuitos de OpenCode no están expuestos mediante una API abierta compatible con OpenAI para proxies de terceros[3]. La arquitectura de transmisión requiere de manera obligatoria la presencia de credenciales autenticadas que el servidor remoto valide antes de iniciar la emisión de paquetes SSE[3].

5. Matriz comparativa de la integración de proveedores

Para ofrecer una visión clara de las capacidades de enrutamiento actuales en OmniRoute y la compatibilidad con diferentes orígenes de modelos, la siguiente tabla resume el estado de cada alternativa:

Tipo de proveedor	Estado en OmniRoute	Exigencia de autenticación	Comportamiento del protocolo SSE	Resultado operativo
OpenCode Free (Keyless)	Eliminado en v3.8.52 (PR #16310)[3]	Ninguna (noAuth: true)[6]	Sin transmisión de eventos / Rechazo 401[6]	Inoperativo; causa bucles de error si se fuerza[6]
OpenCode Zen / Go	Disponible y activo[3]	Clave API legítima de usuario (sk-...)[6]	Eventos SSE estructurados en tiempo real[8]	Totalmente operativo[3]
Nodo Manual OpenAI-Compatible (Sin Key)	Configurable manualmente[13]	Clave ficticia (sk-dummy)[14]	Bloqueo de socket (_eventCount: 0)[13]	Timeout HTTP 499 a los 12–18 segundos[13]
Modelos Locales (Ollama / LM Studio)	Disponible y activo[16]	Ninguna (Entorno localhost)[16]	Transmisión SSE continua e inmediata[16]	Totalmente operativo sin coste[16]
APIs Cloud Gratuitas (Groq / Together AI)	Disponible y activo[7]	Clave API de nivel gratuito del proveedor[7]	Eventos SSE estructurados estándar[7]	Totalmente operativo bajo límites de cuota[7]

6. Conclusiones y recomendaciones definitivas

La investigación realizada permite emitir los siguientes hallazgos y pautas de actuación:

1. **Inexistencia de un problema individual:** No existe ninguna anomalía en la instalación local del usuario ni en su entorno de red. La desaparición de "OpenCode Free" en OmniRoute es el resultado de un cambio oficial en el proyecto publicado el 19 de octubre de 2026 en la versión v3.8.52 para atajar fallos de estabilidad en la base de datos local y responder a las restricciones impuestas por el operador de OpenCode[3].
2. **Explicación del contenido audiovisual de septiembre de 2026:** Los tutoriales en YouTube publicados hace un mes mostraban la versión previa a la v3.8.52, período durante el cual el conector keyless seguía presente en la interfaz gráfica pero ya experimentaba bloqueos upstream masivos y fallos de infraestructura[2].
3. **Inviabilidad técnica del proxy manual sin clave:** Intentar redirigir modelos gratuitos internos de OpenCode (como big-pickle) mediante un nodo genérico compatible con OpenAI sin poseer una clave API de OpenCode Zen o Go dará como resultado invariable un bloqueo silencioso de la conexión y un error de tiempo límite HTTP 499[6].

Recomendaciones estratégicas para el flujo de trabajo

- **Para utilizar los modelos gratuitos de OpenCode (big-pickle):** Se debe prescindir de OmniRoute como pasarela intermedia para estos modelos específicos y ejecutar las peticiones de forma directa desde la aplicación o cliente CLI oficial de OpenCode, el cual adjunta automáticamente las credenciales de sesión de cliente requeridas por sus servidores[3].
- **Para utilizar OmniRoute con el ecosistema de OpenCode:** Registrarse en OpenCode Zen o suscribirse a OpenCode Go, generar una clave de API válida e introducirla dentro del conector autenticado opencode-zen u opencode-go en OmniRoute[3].
- **Para mantener un entorno de enrutamiento 100% gratuito en OmniRoute:** Conectar proveedores que expongan endpoints compatibles con OpenAI con capas gratuitas abiertas, tales como servidores locales de inferencia (Ollama o LM Studio) o servicios cloud con claves API de nivel gratuito (Groq, DeepSeek o Together AI)[7]. Esto garantizará la recepción continua de eventos SSE y el funcionamiento fluido de los agentes de programación sin interrupciones por timeout[13].

Obras citadas

1. OpenCode Vs Omniroute: Which One Do You Need? (2026), https://aiprofitboardroom.com/blog/opencode-vs-omniroute/
2. OpenCode + Omniroute: 100% Free AI Coding Setup (2026), https://juliangoldie.com/opencode-omniroute/
3. opencode free usage problem #17081 - GitHub, https://github.com/cheaper-inference/OmniRoute/discussions/17081
4. OmniRoute + OpenCode: 100% Free AI Coding Setup ... - YouTube, https://www.youtube.com/watch?v=fXke2rmwOps
5. The Free AI Gateway That Unifies 278+ Providers Into One Endpoint, https://www.coddykit.com/pages/blog-detail?id=512955&slug=omniroute-the-free-ai-gateway-that-unifies-278-providers-into-one-endpoint-never
6. [bug] No-auth providers (opencode / opencode-zen) infinite account, https://github.com/cheaper-inference/OmniRoute/issues/3061
7. OmniRoute Setup Guide (2026) — Free AI Gateway for Claude Code, https://deployu.ai/blog/omniroute-setup-guide
8. Zen | OpenCode, https://opencode.ai/docs/zen?ref=huntscreens.com
9. OpenCode Go Review: Is the $10 AI Coding Plan Worth It?, https://thomas-wiegold.com/blog/opencode-go-review/
10. is there any way to bypass OpenCode's free tier can only be used, https://github.com/Alishahryar1/free-claude-code/issues/1816
11. Zen - OpenCode Docs, https://opencode-tutorial.com/en/docs/zen
12. OpenCode Go | Modelos de codificação de baixo custo para todos, https://opencode.ai/br/go
13. omniroute-request-logs-1h-2026-11-01.json
14. Instalación OpenCode, OmniRoute y Ponytail - Apuntes de eduardófilo, https://apuntes.eduardofilo.es/2026-07-26_opencode_omniroute.html
15. Connecting OmniRoute to OpenCode, Open WebUI, and Open Design, https://note.com/taku_oriole5531/n/n5a796345f065?hl=en
16. OmniRoute by Cheaper Inference | #1 Router de IA de código abierto, https://www.omniroute.online/es/
17. AI DevOps + OpenCode: Make Coding Free with Zen Models, https://forum.cloudron.io/topic/15277/ai-devops-opencode-make-coding-free-with-zen-models-no-claude-openai-google